

Modelado de Alquileres en el AMBA: Enfoque Híbrido e Interpretación de Variables Explicativas

Cipriano Oss Teruel y Gonzalo Martín Zabaleta Ferrando

Universidad de San Andrés
gzabaletaFerrando@udesa.edu.ar



Motivación

La tasación automática de precios de alquiler tiene aplicaciones directas: ayuda a inquilinos a detectar ofertas, a propietarios a fijar precios competitivos, y a desarrolladores a evaluar inversiones.

Pero esto en el mercado del AMBA presenta **dos desafíos**:

- **Distribución sesgada**: un 1 % de propiedades de lujo distorsiona el aprendizaje de los modelos.
- **Tradeoff**: un modelo entrenado en propiedades promedio falla en las de lujo, y viceversa.

Además de predecir, buscamos **explicar**: ¿qué características determinan el precio? ¿Cuánto vale una pileta en CABA vs. Zona Oeste? El análisis con SHAP cuantifica el impacto de cada variable.


Distribución del Precio

La distribución de los precios de las propiedades en el AMBA está extremadamente sesgada.

- **Mediana**: \$9.166 (precio típico)
- **Media**: \$27.470 (inflada por outliers)

Hay un pequeño grupo de propiedades de precios extremadamente altos que sesgan la distribución y dificultan el aprendizaje de los modelos

Esto motiva el tratamiento diferenciado del segmento de lujo.




Efecto Espacial No Lineal

Aunque las coordenadas tienen baja correlación lineal con el precio, el efecto de la ubicación es evidente:

- Zona Norte y cercanía al río -¿ precios más altos
- Hexágonos premium aislados en el conurbano -¿ Barrios privados, difíciles de detectar por modelos lineales

Esta alta no-linealidad de la distribución espacial del precio nos es una de las razones por las cuales los modelos lineales no funcionaron bien en este dataset.




Modelo Híbrido

Nuestra propuesta: identificar a los outliers primero, y luego predecir su precio con un regresor especializado.

- **Clasificador XGBoost**: identifica si la propiedad pertenece al 1.5 % más caro o no.
- **Regresor Normal**: entrenado en el 98.5 % de propiedades promedio.
- **Regresor de Lujo**: entrenado exclusivamente en propiedades premium (1.5 % más caro).


Esta arquitectura evita que los outliers distorsionen el aprendizaje del segmento masivo.



Resultados


El modelo híbrido logra una **reducción del 74 %** en MAE respecto al baseline, y un 48 % respecto a un XG-Boost monolítico:

Métrica	Híbrido	XGB Opt.	Baseline
MAE	23,314	45,515	89,264
RMSE	311,949	294,633	364,441
MedAE	934	8,360	35,022



El Patrón en los Errores


El scatter plot confirma buena precisión en la mayoría de las muestras, con dos “nubes” de casos extremos en los que la predicción del modelo está muy alejada del precio real.



¿Cómo se Explica el Precio?

El análisis SHAP revela los principales *drivers* del precio:

- **Superficie construida**: la variable individual más importante
- Seguida por baños, cocheras, ambientes y ubicación
- Gimnasio y pileta son las amenities de mayor impacto
- El resto de amenities tienen un rol secundario




Impacto de Amenities por Zona

Las amenities no impactan lo mismo en todo el AMBA:

- **Gimnasio en CABA**: +\$18,000/mes
- **Gimnasio en Zona Sur**: +\$12,000/mes

Insight accionable: una desarrolladora puede estimar el retorno de inversión de construir amenities según la ubicación.



Conclusiones y Trabajo Futuro

Conclusiones:

- Clasificar el mercado mejora la precisión en el segmento masivo sin eliminar outliers.
- El modelo híbrido es óptimo si se prioriza MAE/MedAE; XGBoost monolítico lo es si se prioriza RMSE.
- Las características relacionadas con superficie y habitabilidad (baños, ambientes, etc.) son las más importantes en el precio

Trabajo futuro:

- Modelado usando PCA
- Clasificador para tratar las nubes del scatter plot
- Incorporar datos socioeconómicos externos
- Explorar arquitecturas de deep learning tabular como TabNet